

Прогнозирование продаж и спроса на новые коммерческие автомобили ГАЗ

Классические модели машинного обучения и TransformerEncoder

Итоговый проект

Период данных: 2019–2025



Группа DS-21, Яна Данилина
Москва, 19.09.2026 г.

ЦЕЛЬ И ПОСТАНОВКА ЗАДАЧИ

Цель — проверить, какие подходы лучше прогнозируют продажи и заявки при сезонности, внешних факторах и рыночных шоках.

Задачи:

- загрузка и объединение исходных данных;
- очистка и подготовка временного ряда;
- исследование трендов, сезонности и структурных изменений;
- создание лаговых признаков и скользящих статистик;
- добавление внешних экономических факторов;
- построение обучающей, проверочной и тестовой выборки без перемешивания наблюдений;
- обучение нескольких прогнозных моделей;
- подбор параметров моделей на проверочном периоде;
- формирование рекурсивного прогноза на 12 месяцев;
- оценка качества прогнозов по нескольким метрикам;
- сравнение моделей с сезонным наивным прогнозом;
- анализ важности признаков и поведения моделей при резких изменениях ряда;
- формирование интерактивного дашборда и файлов с результатами.

Бизнес-ценность

Прогноз продаж и спроса помогает планировать склад, маркетинг, работу дилеров, лизинговые активности и производство.

Проблема

Продажи коммерческих автомобилей зависят от сезонности, экономической среды, ставок, курса валют и рыночных шоков.

Результат для бизнеса

Нужно не просто получить цифру, а сравнить подходы и понять, какой из них устойчивее на тестовом периоде.

ЦЕННОСТЬ ЗАДАЧИ



Решение задачи позволяет принимать более оперативные и правильные управленческие решения

планирование объёмов продаж

оценка будущей рыночной активности

планирование маркетинговой
активности

оценка влияния макроэкономических
условий

управление запасами автомобилей


формирование сценариев продаж

сравнение простых и более сложных
методов прогнозирования


EDA – разведочный анализ

Что показал?

Продажи новых коммерческих автомобилей ГАЗ (quantity) характеризуются выраженной годовой сезонностью и существенными изменениями общего уровня продаж. Наиболее высокие значения обычно наблюдаются в конце года, особенно в декабре, тогда как начало года характеризуется более низким уровнем продаж.



Сдвиг продаж	сила
2025-01	2,27
2022-04	2,19
2020-01	1,49



Сдвиг заявок	сила
2020-04	1,73
2023-01	1,58
2022-02	1,55

МЕТОДОЛОГИЯ



МОДЕЛИРОВАНИЕ

Какие модели сравнивались?

Модель	Идея	Зачем включена
Наивная	Значение того же месяца прошлого года	Базовый ориентир
SARIMA	Статистическая сезонная модель	Сезонность 12 месяцев
Случайный лес	Ансамбль деревьев решений	Устойчивый нелинейный подход
XGBoost	Градиентный бустинг	Сильная модель на табличный признаках
TransformerEncoder	Нейронная модель временных рядов	Проверка сложной архитектуры

Метрики качества

MAE, RMSE, MAPE и SMAPE рассчитаны на последних 12 месяцах тестового периода.

Подбор параметров



Параметры выбираются на проверочной выборке, тест не используется при настройке моделей.

Рекурсивный горизонт

Прогноз строится последовательно на 12 месяцев: предыдущий прогноз становится входом для следующего.

РЕЗУЛЬТАТ: QUANTITY

Результаты прогноза продаж



Лучший результат на тесте



XGBoost: RMSE 612,29, MAE 506,61, MAPE 12,9%.

Интерпретация

Модель лучше других приблизилась к фактической динамике 2025 года, но вывод относится именно к выбранному тестовому периоду.

РЕЗУЛЬТАТ: APPLICATIONS

Результаты прогноза спроса (обращений)



Лучший среди проверенных:

XGBoost: RMSE 9632,98, MAE 8764,29, MAPE 89,9%.


Осторожный вывод:

Даже лучшая модель ошибается сильно: ряд заявок нестабилен и требует дополнительных данных о маркетинге, каналах и правилах учёта лидов.


ИНТЕРПРЕТАЦИЯ

Какие факторы использовали модели?

Продажи: внешние факторы



Заявки: внешние факторы



Важность признаков показывает, на какие переменные опирались модели. Это не доказывает причинность, но помогает понять логику прогноза.

НЕЙРОННАЯ МОДЕЛЬ

Что показал TransformerEncoder?

Продажи

RMSE TransformerEncoder выше XGBoost примерно на 95%.

Заявки

RMSE TransformerEncoder выше XGBoost примерно на 101%.

Причина

В данных всего 84 месяца. Для нейронной архитектуры это ограниченный объём наблюдений.

Практический вывод

- сложная модель не обязательно лучше на малой выборке;
- TransformerEncoder стоит сохранять как исследовательское направление;
- для устойчивого преимущества нужны более частые данные, больше истории и дополнительные признаки.

ИТОГИ И РАЗВИТИЕ

Дальнейшее развитие проекта



1. Расширить данные

Добавить недельные/дневные данные, маркетинговые расходы, каналы лидогенерации, остатки, цены, скидки и данные дилеров.

2. Улучшить проверку

Использовать скользящую проверку по нескольким тестовым окнам, а не только один 2025 год.

3. Построить сценарии

Готовить прогнозы макроэкономических факторов и сравнивать базовый, оптимистичный и стрессовый сценарии.

Итоговый вывод

На выбранном тестовом периоде 2025 года XGBoost показал лучший результат среди рассмотренных подходов. Для продаж качество выглядит приемлемым для дальнейшей проработки, а для заявок ошибка остаётся высокой. TransformerEncoder сохранён в проекте и показывает важный практический вывод: более сложная архитектура не гарантирует выигрыш на малой выборке.